

## 解説

## 周辺環境と技術動向

## リモートセンシングにおける人工知能 (AI) 活用

奥村俊夫\*

## AI Applications in Remote Sensing

Toshio OKUMURA\*

Keywords : 衛星画像, 人工知能, AI, 機械学習, 深層学習, 利用事例

## 1. はじめに

第3次 AI ブームと言われて久しい。この第3次 AI ブームを加速させた革新技術にディープラーニング（深層学習）がある。リモートセンシングの業界でも深層学習に取り組む事例が増えてきている。そのような中、深層学習活用の問題点や、問題解決に向けたいろいろな取り組みが提案されている。一方で、温故知新、改めて従来の物理的なプロセスベースの手法や、伝統的な統計的な手法、深層学習以前の機械学習の手法に立ち返るシーンや、それらを深層学習といった新しい技術と組み合わせた手法の提案が重要と考えられる。また、リモートセンシングの分野で AI を活用する際、これまで蓄積してきた知見をいかに活かせるかという点も重要である。ここでは、筆者が所属する RESTEC の技術成果報告会で発表した内容にもとづき、リモートセンシングにおける人工知能 (AI) の活用について紹介する。発表内容の詳細は、RESTEC ホームページに掲載されている発表資料を参照頂きたい。(https://www.restec.or.jp, トップ>財団情報>RESTEC フォーラム>平成30年技術成果報告会, 2019年技術成果報告会)

まず、AI の歴史を簡単に振り返る。人工知能 (AI: Artificial Intelligence) が生まれた第1次 AI ブームが、1950年代から1960年代と言われている。この段階では AI そのものが社会問題の解決に直結することではなく、ブームは下火となっていった。第2次 AI ブームは1980年代で、エキスパートシステムがブームを牽引する革新技術として注目を浴びた。「もし〇〇なら、△△である」という知識をコンピュータにインプットすることで、特定の課題に対する答えを導くものであった。これは、膨大な知識を入力することが困難な点とルール化された課題以外に対応できない点

などの問題があり、この問題の解決に至ることなく第2次 AI ブームが去っていった。第3次 AI ブームというと深層学習の印象が強いかもしれないが、始まりは1990年代、コンピュータの性能の向上やインターネットの普及が著しく、ビッグデータ時代の到来とともに膨大なデータから必要な情報を選び、コンピュータに学習させる手法、機械学習 (Machine Learning) が、まずあげられる。機械学習のアルゴリズムには主に教師有り学習、教師無し学習、強化学習があげられ、リモートセンシング技術においてもクラス分類や回帰分類といった教師有り学習、またクラスターリングや k-means といった教師無し学習の手法はよく使われているので、慣れ親しんでいる方も多いであろう。2000年代に入ると、ランダムフォレスト (random forests) と呼ばれる、決定木による複数の弱学習器を統合させて汎化能力を向上させる機械学習手法が注目を集め、リモートセンシング技術においても分類、回帰、クラスターリングなどで活用が広がった。そして、今最も注目を浴びている学習手法として深層学習 (Deep Learning) がある。ニューラルネットワークに関する技術は第1次 AI ブーム時代から既にあり、その後、順伝搬型の単純パーセプトロンや多層パーセプトロン、再帰型ニューラルネットワーク、畳み込みニューラルネットワーク、さらに多層の畳み込みニューラルネットワーク、そして学習を階層化することでより複雑な問題に対応出来るようにした深層学習へと発展を遂げてきた。

それでは、ここで、リモートセンシング技術で用いる主な機械学習の手法について、Table 1 に特徴などの概要を整理しておく。

教師有り学習には主に線形回帰・分類 (線形モデル) と非線形回帰・分類 (非線形モデル) がある。線形モデルは比較的単純で説明性が高く、モデルの解釈がしやすいといった特徴がある。一方、非線形モデルは、線形モデルで

(2021. 2. 2 受付, 2021. 2. 9 改訂受理)

\* 一般財団法人リモート・センシング技術センター

〒105-0001 東京都港区虎ノ門3丁目17-1 TOKYU REIT 虎ノ門ビル3階

\* Remote Sensing Technology Center of Japan

Table 1 リモートセンシングで用いる主な機械学習の手法と特徴の概要

主な手法	特徴	留意点
教師有り学習 線形回帰・分類	モデルの説明性が高く、解釈が容易。	複雑な表現は困難。
教師有り学習 非線形回帰・分類	複雑なモデルの表現が可能。 教師データが深層学習に比べて少ない。	モデルの説明性が低く、解釈が難しい。
教師無し学習 クラスタリング	教師データが不要。	結果の解釈は人が行う。
深層学習	画像認識に優れている。	大量の学習データが必要。 モデル構築の計算量が膨大。 モデルの説明性が低い。

は表現しきれない複雑なモデルを表現することができる。モデルが複雑になる分、解釈が難しくなる。線型モデルには、「線形回帰」、「ラッソ回帰」、「パーセプトロン」、「ロジスティック回帰」などがあげられ、非線形モデルには、「k近傍法」、「決定木」、「ニューラルネットワーク」、「サポートベクターマシン」、「ランダムフォレスト」などがあげられる。教師無し学習には「クラスタリング」があげられ、教師データが不要という点が特徴であるが、結果の解釈は人が行うことになる。深層学習は、コンピュータが自ら学習データから特徴量を抽出し、モデルを構築できるため、画像認識に優れている。ただし、活用にあたっては、学習のために大量の学習データが必要な点と、モデル構築に大量の計算を要する点、またモデルの説明性が低い点に留意が必要である。近年、少ない学習データセットで効果的に学習させる手法や、モデルの説明性を高める手法が提案されており、今後これらの手法の利用が広がることが期待される。また、最新技術が故、深層学習は汎用性の高いモデルが構築可能と思われることが多いが、現時点ではまだ特化型 AI とよばれる弱い AI が大半と考える。

## 2. 利用事例

ここでは、リモートセンシングにおける AI の活用事例について、筆者が関わった RESTEC の事業成果から概要を紹介する。

### 2.1 水稻の作柄予測（線形回帰）

まず最初に、シンプルな重回帰の事例を紹介する。農林水産省は、毎年 8 月 15 日現在における都道府県ごとの水稻の作柄概況を公表している。これには多くの現地における実測調査を要していた。そこで、衛星リモートセンシングの活用により、実測調査に係る業務の合理化を図る取り組みが行われた。

予測モデルの構築にあたっては説明可能なモデルであることが条件であった。従って、**重回帰分析による水稻の収量予測モデルの構築を提案した**。過去十数年の収量を、**衛星データと地上で計測された気象データを用いて説明する**

**モデルを重回帰分析により構築する**。使用した衛星データは、**JAXA GSMap の降水量、NASA MODIS の日射量、地表面温度、植生指数**。地上で計測された気象データは、**アメダスの気温、日照時間、降水量、風速**である。教師となる**収量のデータは農林水産省がこれまでに蓄積した全国各地の収量（ha/10a）である**。2 変数から 5 変数程度の重回帰分析により、誤差が小さい上位の式から、専門家との検討を経て生物学的に説明性の高い数式で構成するモデルを構築した。この結果、目的とされた、実測調査に係る業務の合理化を図ることができた。

このように、説明可能なモデルを求められた場合には、線形回帰の手法を用いることが多い。シンプルな手法で問題が解決できるのであれば、あえて複雑な手法を選択する必要はない。

本取り組みに関する資料は、農林水産省のホームページで公開されているため、「**人工衛星からの取得データを利用した水稻作柄予測手法の導入について**」をキーワードに検索頂きたい。

### 2.2 農地の作物分類（非線形分類）

次は、非線形分類の事例である。引き続き農林水産省の事例で、同省が毎年行っている作物統計調査における現場実測作業を衛星リモートセンシングと AI 技術を用いて効率化を図る取り組みである。

手法開発にあたっては、農林水産省がこれまでの調査で蓄積したデータを用いることが条件となった。利用できる教師データの内容（数、バリエーション、バランス）から、深層学習ではなく、**ランダムフォレストによる分類手法**を採用した。衛星データは観測頻度が高く、空間分解能が高い **Planet Scope** を用い、多種多様な作物の特徴を捉えられるよう、時系列データセットを用いた学習を行った。**衛星データの**前処理で、**農林水産省が無償で提供する農地区画のデジタルデータ（筆ポリゴン）**を用いて、**農地だけを解析対象とした**。本事例は、手法開発中の事業のため、詳細は控える。

AI の学習において、学習に最適な教師データがそろっているケースは希である。また、年に 1 回から数回しか裁

培されない農作物のように、**短期間で目的に応じた教師データを作ることが難しいケースも多い。このような制約の中で、どのように AI の学習を行っていくかについては、工夫が必要である。前述の通り、近年、少ない学習データセットで効果的に学習させる手法が提案されており、今後学習の効率化が期待される。**

本取り組みに関する資料は、農林水産省のホームページで公開されているため、「画像解析による農地の区画ごとの作付状況の把握手法の開発」をキーワードに検索頂きたい。

### 2.3 漁場推定 (非線形分類)

本事例は、JAXA の業務で行った**サンマとスルメイカの漁場推定**を行った事例である。

本事例の実施に当たっては、教師データとなる漁場データの収集が困難であったことから、衛星リモートセンシングの技術を用いて、教師データを生成することとした。具体的には、**NOAA の suomi NPP の夜間光データをもとに漁船を抽出し、漁船の明かりを漁り火と仮定しその場所を漁場とした。説明変数に用いたデータは、いずれも衛星データ由来のプロダクトを用いた。NASA MODIS の海面水温とクロロフィル a 濃度、欧州 Copernicus の海面高度アノマリ (MSLA) と地衡流速、地衡流速から算出した渦運動エネルギー (EKE)、そして COPAS が配信している HYCOM の鉛直水温である。これらの教師データと説明変数データから学習データセットを作成し、サポートベクターマシンやランダムフォレストなどの手法で漁場の推定モデルを構築した。残念ながら、現地の検証データによる検証には至らなかったが、教師データから説明変数データといった学習データセットの全てを、現地実測調査によるデータに依存することなく、衛星由来のデータのみから作成し、学習モデルを構築した事例として紹介させていただいた。**

本事例に関する資料は、RESTEC 平成 30 年技術成果報告会資料にまとめているため、RESTEC ホームページから閲覧頂きたい。

### 2.4 定置網の形状診断 (非線形分類)

本事例は、内閣府の「平成 30 年度先進的な宇宙利用モデル実証プロジェクト」において採択を受け、実施したものである。定置網は、台風や高波などにより網の形状が変化すると、漁獲量に影響が出るため、形状変化を都度確認する必要がある。ところが全長 500 m ほどある定置網全体の形状変化の確認は容易ではなく、**衛星により効果的に網の形状を監視できるかの実証を行った。**

ここでは、観測頻度が高い **Planet Scope** の衛星画像を用い、定置網の形状を自動識別できるかを検証した。衛星画像から定置網の形を判読により特定し、教師データを作成した。説明変数は **Planet Scope の 4 バンドの画像を用い、更に物体検出に有用な局所特徴量を高次元に (100 種類以上) 作成し、説明変数に加え、学習データセットを作成した。学習手法は、次元数が多い学習データセットに強いラ**

ンダムフォレストを採用した。モデルの検証を進める中で、波を網と間違える傾向があったため、波を網ではないという教師データを追加し、網の検出精度を向上させた。本実証内では、網の形状を自動識別できる可能性を確認することができたが、サービス化までは至らなかった。

深層学習による物体検出が注目を浴びる中、十分な教師データ、説明変数データを得られない場合でも、学習データセット作成の前段階で局所特徴量を算出するといった画像解析技術を活用することで、深層学習ほどの学習データ数がなくても、ランダムフォレストで解決できる事例として紹介させていただいた。

本事例に関する資料は、RESTEC2019 年技術成果報告会資料にまとめているため、RESTEC ホームページから閲覧頂きたい。

### 2.5 農地の変化抽出 (深層学習)

最後に、深層学習の事例を紹介する。**農林水産省が整備し無償で公開している全国 3,000 万筆の農地区画のデジタルデータ「筆ポリゴン」、このデータの更新を衛星データを用いて効率よく行うことで、これまで全国の更新に 5 年を要していたところ、1 年で更新できるようにするといった取り組みである。**

ここでは、高空間分解能かつ高頻度観測により日本全国の雲無しモザイクが毎年季節毎に作成可能な Planet Scope を用いることとした。四季の画像から農地の変化抽出に最適な時期を検証し、夏期のモザイクデータセットを使用することとした。教師データは、最新の筆ポリゴンデータと 1 世代前の筆ポリゴンデータを用いて変化箇所の教師データを作成した。説明変数データには、1 世代前の筆ポリゴンをラスタ化した画像と、最新の筆ポリゴンの更新年の Planet Scope 画像を用いた。深層学習により変化抽出モデルを構築する際、変化を漏れなく抽出することを優先する方針とし、Recall と Precision のバランスは Recall を優先するようチューニングを行った。日本全国の衛星画像から農地の形状変化を抽出することで、ピンポイントで変化の確認および更新作業を行うことができ、効率化を図ることができた。

リモートセンシング関係者が陥りやすい変化抽出の固定概念として、変化前後の衛星画像を比較することで変化を抽出しようとするのが考えられる。この事例の場合、従来の手法が、最新の衛星画像に更新対象の筆ポリゴンを重畳して、変化の確認および更新を行うというものであった。AI を学習させるための学習の課題設定として、この従来の運用方法を踏襲することとし、変化前は更新対象筆ポリゴン、変化後は最新の衛星画像で運用可能な AI モデルを構築することとした。これは、運用上の制約を解決するために必要な判断であった。これまでの経験から、更新対象の筆ポリゴンが古く、対応する衛星画像が入手できないことが想定でき、変化前の情報として衛星画像を使う変化抽出モデルでは、実運用にそぐわないことが予測できた。そのため、変化前の情報に衛星画像を使わないことを制約条



件として、学習方法を検討した。従来手法において変化前の情報として更新対象の筆ポリゴンを重畳していたことから、変化前の筆ポリゴンと変化後の衛星画像で、十分に变化抽出が可能な情報量が得られていると考えた。これには、変化前の衛星データ費用の削減や、学習量を減らすことでシンプルなモデルを構築できるという副次的効果があり、結果、農林水産省の全国3,000万筆の筆ポリゴンに対して、変化抽出が可能な運用システムを実現することができた。

なお、本取り組みに関する資料は、農林水産省のホームページで公開されているため、「人工知能（AI）を活用した筆ポリゴンの迅速な更新の実現」をキーワードに検索頂きたい。

### 3. リモセン×AIのポイント

AIの学習を我々の勉強に例えるなら、「学習するAIは生徒」、「学習に用いるデータセットは、教科書などの教材」、「AIを用いて問題可決をする当事者は、教師」と考えることができる。我々リモートセンシングに係わる研究者や技術者は、この場合「教師」の立場である。教師は、「教材」である学習データセットを準備する役割も担う。どんなに優秀な「生徒」であっても、教材と教え方次第でその結果が決まることから、教師の役割は大きい。そして、「生徒」に該当するAIは、多くの場合、AI分野の専門家の役割と考える。

ここでは、前述の利用事例を踏まえ、衛星リモートセンシングにおいてAIを活用する際のポイントを簡単に整理する。

#### 3.1 適切な課題の設定

AI活用にかかわらず必要なことであるが、解決したい課題がどのような課題であるかを分析し、前提や制約などの条件を含め解くべき課題を明確に設定する。その後、解決のためのアプローチを設計し、必要な教材を準備し、どの能力をもった生徒を起用・育成するかを考えることになる。運用システムを実装する際には、要求仕様を満たすだけでなく、顧客が実現したいことが実現できるかという「妥当性」についても検討する必要がある。

#### 〔著者紹介〕

##### ●奥村 俊夫（オクムラ トシオ）



1972年生。1997年金沢工業大学大学院修士課程修了（情報工学）。1997年（財）リモート・センシング技術センター（RESTEC）入社、開発部、研究開発部等を経て、2021年ソリューション事業第二部 参事。地球観測衛星の地上設備の開発、農業リモートセンシングの社会実装をはじめ、林野、水産、災害把握、都市計画など多分野において、リモートセンシング技術と異分野技術を活用した社会課題解決に取り組む。

E-mail : okumura@restec.or.jp

#### 3.2 課題に適した学習手法の選定

近年、AIを利用する環境が整い、一般的な学習手法はツール化され、利用事例で紹介した範囲であれば、AIの専門家でなくてもAIを扱えるようになってきた。リモートセンシングでAIを活用する際、まずはAIを問題解決の道具として使えることが重要で、問題解決に適した道具がどれかを適切に選定でき、道具として使いこなせる知識を得ることが重要である。道具化されていないAIの手法を使わざるを得ない場合には、AIの専門家と組むことを考えたい。

最初の水稲の作柄予測の利用事例で紹介したとおり、あえて複雑な手法を選択する必要はない。定置網の形状診断の利用事例などのように、学習データセットの工夫や、学習すべき課題の設定を見なすことで解決できる場合もある。

#### 3.2 効率的な教師データの作成

前述の利用事例で紹介したとおり、AIの学習において、学習に最適な教師データがそろっているケースは希である。漁場推定の利用事例で紹介したとおり、工夫次第では、衛星リモートセンシングデータから大量の教師データを効果的に作成できる可能性がある。

#### 3.3 効果的な説明変数データの作成

一般的に、AIモデル構築作業において、7割以上がデータ収集と前処理と言われている。筆者の経験からも同じ考えである。漁場推定や定置網の形状診断の利用事例で紹介したように、これまでのリモートセンシング技術の研究や開発で培った知識や画像解析技術を用いることで、学習に効果的な説明変数を効率よく作成できる可能性がある。

### 4. おわりに

今後もAIの技術革新は進み、優秀なAIが登場し、高精度で汎用性の高いモデルを構築できるようになることが想像できる。そのとき、優秀なAIに価値のあるデータを提供できるよう、リモートセンシング技術の向上に努めることや、リモートセンシングとAIを活用して課題解決ができる利用分野の開拓に努めることが重要と考える。

利用事例を踏まえ、リモートセンシングにおいてAIを活用する際の留意事項について、筆者の観点からまとめた。参考になれば幸いである。